

基于冻结 DINOv2 特征重建的工业图像异常检测技术报告

摘要

本文介绍一个面向工业图像异常检测与定位的离线方案。该方案以本地保存的 DINOv2 `vit_base_patch14_reg4` 为特征编码器，冻结编码器参数，仅训练轻量的瓶颈网络和 Transformer 解码器。训练阶段，模型学习重建正常图像的多层特征；推理阶段，以编码特征和重建特征之间的余弦距离构建连续的像素级异常图，并由高响应区域汇聚得到图像级异常分数。

项目采用单一共享模型，可随训练 manifest 中实际出现的类别集合训练和保存模型，而不依赖固定类别名称。训练与推理均通过命令行接收数据、manifest、模型和输出路径；预训练权重、模型权重及分数归一化参数均以本地文件形式加载，从而支持断网环境下运行。推理按照 `category` 和 `image_name` 对应每个输入样本，在各类别的 `pred.json` 中输出 `[0,1]` 范围的图像级分数，并保存与原图同尺寸的二维 `float32 .npy` 像素异常图。

实验保留历史最佳基准 V4，并补充记录了 `0aea8ed`、`46f2b982` 和当前版本的公开开发集结果。所有横向比较均使用统一的五项加权平均分，避免不同评测通道的旧加权平均口径混用。

关键词： 工业异常检测；无监督学习；DINOv2；特征重建；像素级定位

项目分工

叶浩权

- **模型优化方案研究：** 针对模型在图像级判别与像素级定位之间的性能差异开展优化研究，分析预处理、特征层融合、异常图生成、图像分数汇聚、难例挖掘和分数校准等环节对评测指标的影响，并据此制定具体的优化方案与实验计划。
- **模型优化方案实施：** 将确定的优化方案落实到当前模型代码和配置中，完成相关参数调整、功能改造与版本迭代，并依据训练和评测结果检查优化效果。
- **测试文件编写与验证：** 编写模型改造所需的测试文件与测试用例，对数据读取、模型加载、训练流程、推理流程、输出目录结构、预测文件格式和关键数值范围进行验证，并完成改造后的回归测试。
- **本地评估脚本编写：** 编写并调试本地评估脚本，实现 Image F1、Image AP、Pixel F1、Pixel AP、Pixel AUROC 及统一加权平均分的计算，用于模型版本比较和提交前结果核验。

陈羿锦

- **总体方案与初始模型架构：** 完成任务需求分析与总体技术路线制定，并负责模型最初版本及整体架构的设计与实现；构建以冻结 DINOv2 编码器、特征瓶颈和 Transformer 解码器为核心的特征重建架构，实现基于编码—解码特征差异的图像级异常判别与像素级异常定位流程。

- **项目架构设计与基础工程实现：** 设计项目代码结构和模块边界，完成数据集与 manifest 解析、基础图像预处理、模型构建、配置管理、随机种子控制以及公共工具模块等基础功能。
- **训练与推理主流程：** 设计并实现训练入口、训练循环、优化器与学习率调度接入、模型权重及运行配置保存，以及推理入口、离线模型加载、逐类别预测和异常图恢复等核心流程。
- **评测接口与交付适配：** 根据比赛接口规范设计预测结果组织方式，完成 pred.json、二维 float32 异常图及模型目录结构的接口适配，并负责离线依赖、预训练权重、运行参数和提交材料的整体整合。
- **模型优化方案指导：** 对模型优化目标、技术方向和实验优先级提供指导，参与优化方案评审，结合图像级和像素级指标变化提出调整建议，并把控优化方案与总体架构及比赛约束的一致性。
- **项目统筹与成果整理：** 负责除叶浩权上述专项工作之外的项目推进，包括版本组织、训练与预测任务协调、实验结果汇总、技术报告整理以及最终交付内容的检查与确认。


1. 问题定义与方案概述

工业视觉检测既要判定一张图像是否存在异常，也要定位异常所在区域。设输入图像为 x ，模型输出：

- 图像级异常分数 $s(x) \in [0, 1]$ ，数值越大表示图像越可能异常；
- 像素级异常图 $A(x) \in [0, 1]^{H \times W}$ ，其中 (H, W) 与原始输入图像的尺寸一致。

本方案属于特征重建式异常检测。在通常的无监督设定中，训练 manifest 由正常图像构成，模型据此学习正常外观和结构表征；当输入图像含有未见异常时，异常位置更难被准确重建，编码特征与解码特征之间的差异会升高，从而形成异常响应。项目不读取标签列，而是强制校验训练 manifest 的每条 image_path 均位于 train/good 路径下，防止训练阶段误用测试图或异常图。

整体流程如下：



2. 数据接口与预处理

2.1 Manifest 驱动的数据读取

项目通过 `src/core/manifest.py` 读取 CSV manifest。训练时读取 `category` 与 `image_path`，并校验每条路径均指向 `train/good` 正常图像；推理时还要求 `image_name`，其格式为 `test/<文件名>`。所有 `image_path` 均相对于命令行传入的 `--data-root` 解释，程序还会拒绝绝对路径、路径穿越、`ground_truth` 引用及重复样本，因此实现不依赖固定盘符、目录扫描结果或硬编码类别列表。

`src/data/dataset.py` 按 manifest 的每一行读取图像。为兼容中文及其他非 ASCII 路径，图像读取使用 `np.fromfile` 与 `cv2.imdecode`，随后由 BGR 转为 RGB。推理数据集会额外记录原始高度和宽度，以便将模型输出的异常图恢复到原始图像尺寸。

2.2 图像变换

默认几何变换由 `src/core/preprocess.py` 和 `src/data/dataset.py` 共同实现，训练与推理使用同一流程：

- 1. 按原始宽高比将 RGB 图像缩放至可完整放入 560×560 画布；
- 2. 使用 RGB 值 (124, 116, 104) 居中填充至 560×560 ，不进行中心裁剪；
- 3. 转换为 `[0,1]` 的 float 张量；
- 4. 使用 ImageNet 的均值 (0.485, 0.456, 0.406) 和标准差 (0.229, 0.224, 0.225) 归一化。

Letterbox 预处理保留完整图像内容，并记录原始尺寸与四边 padding。输出时，`src/engine/predict_engine.py` 先移除异常图的填充区域，再线性插值回原始图像尺寸。训练损失还会使用 patch 覆盖率掩膜，降低填充区域对特征重建的影响。

3. 方法设计

3.1 冻结的 DINOv2 特征编码器

编码器为 `vit_base_patch14_reg4_dinov2`，预训练权重文件为 `dinov2_vitb14_reg4_pretrain.pth`。默认配置位于 `configs/default.json`，其核心设置为：

模块	设置
主干网络	DINOv2 ViT-Base, patch size 为 14
特征维度 / 注意力头数	768 / 12
取用的编码器层	<code>blocks.2</code> 至 <code>blocks.9</code> ，共 8 层
主干参数	全部冻结

模块	设置
计算精度	float32

`src/models/dinomaly/model.py` 在建模后将所有参数冻结，再仅解冻 `bottleneck` 和 `decoder`。这一设计保留通用预训练视觉特征，同时避免在仅含正常样本的训练条件下对大规模主干进行过拟合，并降低训练所需的可学习参数量。

3.2 特征重建网络

模型主体定义于 `src/models/dinomaly/torch_model.py`。编码器输出的多层 token 特征先按层分组取均值融合，再经一个 MLP 瓶颈和 Transformer 解码器处理。

- **瓶颈层：**由 `DinomalyMLP` 实现，隐藏层维度为 4×768 ，激活函数为 GELU，默认 dropout 为 0.3。
- **解码器：**默认深度为 6，每层为 `DecoderViTBlock`。注意力模块使用 `LinearAttention`：先对 Q 、 K 施加 $\text{ELU}(\cdot) + 1$ 映射，再计算线性复杂度的注意力聚合。
- **层间融合：**编码器默认取 `blocks.2` 至 `blocks.9` 共 8 层，并按前 4 层、后 4 层形成两组；深度为 6 的解码器按前 3 层、后 3 层形成两组。每组内部取均值，得到两组对应的空间特征。

对于包含类别 token 与 register token 的特征序列，当前默认设置不直接将其用于空间异常图。实现依据图像 patch 数取最后 $H_p \times W_p$ 个 token，并将其还原为二维特征图，从而使异常定位对应图像空间位置。

3.3 训练目标：余弦重建与难例挖掘

对第 l 组编码器空间特征 F_l^e 与对应的解码器特征 F_l^d ，基础重建误差采用余弦距离：

$$d_l = 1 - \cos(F_l^e, F_l^d).$$

训练损失由 `src/models/dinomaly/components/loss.py` 中的 `CosineHardMiningLoss` 实现。该损失对各特征组的余弦距离加权平均，并在反向传播时降低易重建位置的梯度贡献。训练开始后的前 1000 个优化步将降权比例从 0 线性提升至 0.8；每张图保留距离最高的至少 20% 有效 patch 为难例，其权重为 1，其余有效 patch 的权重为 0.1。Letterbox 边界 patch 按有效像素覆盖率继续加权，纯填充 patch 不进入损失。这样可使训练更关注难以重建的有效图像区域。

3.4 像素级异常定位与图像级判别

推理时，模型对每组特征计算空间余弦距离并插值至输入尺寸：

$$A_l = \text{Upsample}(1 - \cos(F_l^e, F_l^d)),$$

再按两组权重 0.65 和 0.35 融合，得到连续异常图：

$$A = 0.65A_1 + 0.35A_2.$$

像素分支随后使用核大小为 5、 $\sigma = 1.2$ 的高斯平滑，输出定位结果。图像分支独立使用两组原始距离图：先按 0.5/0.5 融合，再根据 letterbox padding 裁出有效图像区域，得到 A_{img} ；然后将其缩放到 256×256 ，施加核大小为 5、 $\sigma = 4$ 的高斯平滑，并取响应最高的 1% 像素均值：

$$s_{\text{raw}} = \text{mean}(\text{Top}_{1\%}(\text{GaussianBlur}(A_{\text{img}}))).$$

训练结束后，`src/engine/train_engine.py` 会在训练 manifest 上分别统计图像原始分数与像素异常图的最小值和最大值，并保存为 `auxiliary/thresholds/minmax.json`。像素异常图使用线性 min-max 归一化并裁剪至 $[0, 1]$ 。图像分数则采用以正常训练分数区间中点为中心的 arctan 映射：

$$s = 0.5 + \frac{1}{\pi} \arctan \left(\frac{s_{\text{raw}} - (s_{\text{min}} + s_{\text{max}})/2}{s_{\text{max}} - s_{\text{min}}} \right).$$

该映射将有限分数压缩到 $(0, 1)$ ，同时避免线性裁剪把超过正常区间上限的异常样本压成大量并列分数。对应实现位于 `src/utils/normalization.py`。

3.5 创新点分析

- 面向多类别的单模型特征重建：** 项目不为类别维护独立模型，而是通过共享的冻结编码器、瓶颈和解码器学习 30 个产品类别的正常特征分布，在保持统一推理接口的同时提高模型复用程度，体现单模型多类别泛化能力。
- 图像级与像素级分支解耦：** 像素定位采用偏向细粒度响应的特征组权重与平滑参数；图像判别则先裁除 letterbox 填充区域，再独立融合多组特征并汇聚高响应区域。该设计减少填充区域和像素后处理对图像级排序的干扰，使两类任务能够分别选择更合适的后处理策略。
- 覆盖率感知的难例挖掘：** 训练损失以 patch 的有效图像覆盖率作为权重，排除纯填充区域，并逐步提高难例挖掘比例，使模型将主要学习能力用于真实图像内容中较难重建的正常模式。
- 随模型交付的双分支校准：** 训练结束后分别统计图像原始分数与像素异常图的校准范围，并将图像评分配置和校准参数随模型包保存。推理阶段校验两者的一致性，降低训练与推理配置漂移造成的结果变化。

4. 训练策略与实现配置

4.1 默认超参数

下表列出 `configs/default.json` 中的默认训练设置。

项目	默认值
batch size	2
最大训练步数	4000

项目	默认值
优化器	StableAdamW
初始 / 基础学习率	0.002
最终学习率	0.0002
warmup 步数	100
AdamW betas	(0.9, 0.999)
权重衰减	0.0001
优化器内部裁剪阈值	1.0
全局梯度范数裁剪	0.1
梯度累积步数	4
随机种子	2026

优化器和调度器定义于 `src/models/dinomaly/components/optimizer.py`。StableAdamW 在 AdamW 更新中引入基于 RMS 的更新幅度缩放；学习率采用先 warmup 后余弦退火的 WarmCosineScheduler。

4.2 模型保存与加载

训练入口 `src/train.py` 调用 `src/engine/train_engine.py`，在 `--output-dir` 下生成完整的模型包：

```
<output-dir>/
├─ shared.pth
├─ model_manifest.json
├─ run_config.json
├─ auxiliary/
│   └─ pretrained/dinov2_vitb14_reg4_pretrain.pth
└─ thresholds/minmax.json
```

其中 `shared.pth` 保存 `state_dict`、模型配置和随机种子；`model_manifest.json` 保存模型模式、权重文件名、训练 manifest 中实际出现的类别、图像分数范围、预处理配置及模型结构参数；`run_config.json` 记录本次训练配置。推理入口 `src/predict.py` 通过 `src/models/builder.py` 从 `--model-dir` 加载上述文件，并校验 image scoring 配置与校准参数一致，不依赖硬编码的本地模型绝对路径。

5. 推理输出与接口适配说明

5.1 推理流程

src/engine/predict_engine.py 严格按推理 manifest 逐条处理样本，并沿用原始 image_name 作为 pred.json 的键和异常图相对路径的一部分。模型切换至 eval() 模式，且推理循环位于 torch.inference_mode() 内。若某一输入、模型文件或输出发生错误，异常会向上抛出并使程序非零退出，而不会静默跳过样本。

输出目录结构如下：

```
<output-dir>/
├── <category>/
│   ├── pred.json
│   └── pred_maps/
│       └── test/
│           └── <filename>.npz
```

每个类别的 pred.json 以 manifest 中的 image_name 为键，条目包含有限的 [0,1] 图像异常分数 anomaly_score 和 .npz 相对路径 anomaly_map 。每幅像素异常图均由 src/utils/image_io.py 保存为二维 float32 数组，数值位于 [0,1] ，且在去除 letterbox 填充后恢复到原图宽高。

5.2 交付约束的对应关系

下表说明的是当前项目实现与评测接口的对应关系，不将接口文件中的要求作为模型效果或实验结果的事实依据。

交付关注点	项目中的实现依据
路径由命令行传入	src/core/args.py 使用 argparse 接收 --data-root、--manifest、--output-dir、--device、--num-workers；训练额外接收 --seed，推理额外接收 --model-dir。
按清单处理数据	src/core/manifest.py 解析 manifest，训练与推理均由 ManifestDataset 按行读取相对路径。
共享模型与类别适配	model_manifest.json 的 model_mode 为 shared；训练时从 manifest 动态收集并保存类别集合。
离线模型加载	编码器权重、shared.pth 与 minmax.json 从模型目录加载；主干创建时显式使用 pretrained=False，不在运行期下载权重。
连续定位分数	模型输出余弦距离异常图，保存为二维 float32 .npz，而非二值掩膜。
图像级分数范围	normalize_image_score 将有限图像分数保序映射至 (0,1)，并以 image_name 写入各类别的 pred.json。

交付关注点	项目中的实现依据
可复现设置	src/core/seed.py 设置 Python、NumPy、PyTorch 和可用 CUDA 的随机种子；本报告采用种子 2026 记录实验。

需要说明的是，当前 `set_seed` 默认未主动开启 cuDNN 的确定性开关。因此，若在不同硬件、CUDA/cuDNN 或依赖版本下复现，仍可能存在少量数值差异；复现实验应固定软件环境、硬件条件和随机种子。

5.3 合规与部署边界

- 训练入口只读取 manifest 中的 `train/good` 正常图像，并拒绝 `test`、`ground_truth` 和不符合正常训练目录结构的路径；推理入口同样只处理 manifest 明确列出的样本，不扫描完整数据目录。
- 项目声明不使用 Omni-AD 之外的工业异常检测数据。DINOv2 权重属于公开通用预训练权重，其来源和 SHA256 记录于 `pretrained_manifest.json`，实际权重随模型包提供。
- 数据、manifest、模型和输出位置均通过命令行参数传入；源码、配置、README 和本报告不记录本机盘符、用户目录或固定数据集位置。
- 推理不访问标签、缺陷类型目录或 `ground_truth`，不联网、不动态安装依赖，也不请求人工输入。任一样本处理失败时程序返回非零退出码，不静默跳过。
- 比赛要求端到端单张推理时间不超过 100 ms、推理峰值显存不超过 24 GB。两项部署指标需要在组委会指定硬件和 Docker 环境中最终测量，本报告不以开发机器结果替代正式平台结果。

6. 实验

6.1 实验目的

实验从两个层面验证方案：其一，评估模型对异常图像的识别能力；其二，评估模型对缺陷区域的像素级定位能力。历史 V1–V6 结果中，V4 的像素级表现最佳，故将其保留为基准；随后加入两次官方通道截图和当前模型的本地评估结果，观察图像级与像素级指标的变化。

6.2 数据集与数据划分

本次训练采用仅含正常图像的训练集；评测集同时包含正常图像和缺陷图像。评测标注包括图像级正常/异常标签和像素级缺陷掩膜，因此可同时计算图像级与像素级指标。训练集的样本总数未在现有评测记录中单独给出，本文不据此臆测其数值。

项目	设置或统计
类别数	30

项目	设置或统计
训练集	仅正常图像
评测集	正常图像 + 缺陷图像
评测集正常样本数	773
评测集缺陷样本数	1439
评测集图像总数	2212
标注	图像级标签 + 像素级缺陷掩膜
类别分布	存在不均衡：各类别正常样本数为 2–102，缺陷样本数为 2–240

表中的评测集统计来自各版本结果中的 ALL 行。类别不均衡意味着仅报告将全部样本汇总后的结果并不充分，因此本节同时报告全局（Global）与按类别宏平均（Macro Average）结果。全局统计将所有评测图像/像素直接汇总；宏平均则先在每个类别内计算指标，再对 30 个类别取算术平均。

6.3 实验环境与实现细节

实验运行于 NVIDIA RTX 5060 GPU 和 Intel Ultra 7 255HX CPU 环境，使用 Python 3.14 与 CUDA 13.0。当前 requirements.lock 固定 PyTorch 2.14.0、TorchVision 0.29.0、NumPy 2.5.2 和 OpenCV 5.0.0.93。历史版本的完整配置差异没有全部留档，所以下表仅陈述当前项目可由 configs/default.json 和源码确认的设置。

项目	当前版本设置
编码器	vit_base_patch14_reg4_dinov2
编码器权重	model/auxiliary/pretrained/dinov2_vitb14_reg4_pretrai
可训练模块	bottleneck 与 decoder；编码器冻结
特征层	默认 blocks.2 至 blocks.9
输入变换	保持宽高比缩放并填充至 560×560 ，ImageNet 归一化
填充设置	常量填充，RGB = (124, 116, 104)
bottleneck dropout / decoder depth	0.3 / 6
remove_class_token	false
use_context_recentering	false
精度	float32
异常图融合 / 平滑	两组权重 0.65/0.35；核大小 5， $\sigma = 1.2$
图像分数	有效区域内两组 0.5/0.5 融合， 256×256 ，top 1%

项目	当前版本设置
batch size / 梯度累积 / 最大训练步数	2 / 4 / 4000
优化器	StableAdamW , lr = 0.002, betas=(0.9, 0.999), weight decay=0.0001
学习率调度	100 步 warmup, 随后余弦退火至 0.0002, 总计 4000 步
梯度裁剪	训练循环全局范数 0.1; 优化器内部阈值 1.0
随机种子	2026

6.4 评价指标

评测从图像级判别和像素级定位两方面进行。给定连续图像分数或连续像素异常图，AP 衡量 Precision–Recall 曲线下的面积，AUROC 衡量不同阈值下的排序区分能力。F1 在所有有效阈值中取最大值，因此以下报告明确写为 **F1-max**，并同步给出取得该值的阈值 τ ；这避免将最优阈值 F1 与任意固定阈值 F1 混淆。

评价维度	指标	含义
图像级	Image AUROC	正常图像与异常图像的排序区分能力
图像级	Image AP	异常图像识别的 PR 表现
图像级	Image F1-max	最优阈值下的图像级异常判别能力
像素级	Pixel AUROC	正常与异常像素的排序区分能力
像素级	Pixel AP	连续异常图对缺陷像素的定位质量
像素级	Pixel F1-max	最优阈值下的二值缺陷区域定位能力

为统一历史记录与当前本地评估器，本报告使用与评测截图一致的 $[0, 1]$ 加权平均分，并同时给出百分比：

$$S_{\text{weighted}} = 0.25 \text{ Pixel F1} + 0.25 \text{ Pixel AP} + 0.15 \text{ Image F1} + 0.15 \text{ Image AP} + 0.20 \text{ Pixel AUROC}.$$

该分数同时使用 F1 和 AP：Pixel F1/AP 分别占 25%，Image F1/AP 分别占 15%，Pixel AUROC 占 20%，权重之和为 1。Image AUROC 与 Pixel AUPRO 保留为诊断指标，但不参与该统一加权平均。正式比赛分还需用全体参赛队伍对应指标的 `metric_best` 进行归一化；本节的 S_{weighted} 仅用于本地版本比较。

6.5 历史最佳基准：版本 4

版本 4 使用当时的默认超参数，是历史 V1–V6 记录中像素级表现最好的基准。表中 Global 为所有评测样本及像素汇总后的结果，Macro Average 为逐类别计算后在 30 个类别上的宏平均。数值均保留至 4 位小数。

统计口径	Image AUROC	Image AP	Image F1-max	τ_{img}	Pixel AUROC	Pixel AP	Pixel F1-max	τ_{pixel}
Global	0.8398	0.9096	0.8311	0.3038	0.8336	0.1190	0.2139	0.1606
Macro Average	0.8755	0.9193	0.8991	0.5846	0.8696	0.1987	0.2787	0.1347

从 Global 结果看，版本 4 的 Image AP 为 0.9096，Pixel AP 为 0.1190、Pixel F1-max 为 0.2139。其 Macro Average 的五项指标重算后，加权平均分为 **0.5660 (56.6%)**，作为后续版本的统一基准。

6.6 后续版本的统一对比

下表保留历史最佳 V4，并加入两次官方评测截图和当前模型的本地评估结果。两个后续提交版本由对应记录确定；当前版本是本报告更新时的模型输出。所有数值为 30 类宏平均，– 表示该次记录没有给出或当前本地评估器未计算该诊断指标。指标列统一保留 4 位小数；当前版本的加权分以评估器输出的未截断指标计算，故与表内四舍五入后的手算值可能存在末位差异。

记录	Image AUROC	Image AP	Image F1-max	Pixel AUROC	Pi
历史基准 V4	0.8755	0.9193	0.8991	0.8696	0.1
0aea8edd17a0d0d37ee7311a841ca0e05c060953	0.8799	0.9204	0.8886	0.8868	0.1
46f2b982d34fbb4c242273408cb848a2e4a2410e	0.5533	0.7024	0.8053	0.9679	0.3
当前版本	0.8896	0.9331	0.9130	0.9685	0.3

0aea8ed 的图像级指标较高，但像素 AP 和 Pixel F1-max 较低，因此统一加权平均分仅略高于历史 V4。46f2b982 显著提高了像素 AP、Pixel F1-max 和 Pixel AUROC，但图像级指标下降，统一加权平均分提升至 0.6276 (62.8%)。当前版本在保持较高像素指标的同时恢复并提升了图像级 AP/F1，取得当前记录中最高的统一加权平均分 0.6724 (67.2%)。

两张官方截图中显示的原始“加权平均分”分别为 0.5213 (52.1%) 和 0.5889 (58.9%)，其组成指标与当前统一五项公式不同，故本报告保留截图原始指标，但统一重算用于版本排序的加权平均分。所有版本比较均以表中最后一列为准。

6.7 实验结论

按统一的五项加权口径，当前版本相对历史基准 V4 提升 0.1064，即 10.6 个百分点；相对 46f2b982 提升 0.0448，即 4.5 个百分点。当前版本的 Pixel AP 和 Pixel F1-max 仍明显高于历史 V4，同时 Image AP 和 Image F1-max 分别达到 0.9331 和 0.9130。基于现有公开开发集记录，当前版本是应优先用于后续预测和提交验证的模型；正式排名仍取决于组委会的 `metric_best` 归一化及盲测结果。

7. 局限性与改进方向

1. 当前图像级分数在去除 letterbox 填充后的有效区域上进行两组特征等权融合，再取平滑后最高 1% 响应的均值。该比例是固定超参数，面对面积差异较大的缺陷时仍可继续比较其他汇聚比例或自适应策略。
2. Letterbox 保留了完整图像内容，但较长一边固定缩放至 560 像素，极细小缺陷仍可能因下采样损失细节。后续可在显存和 100 ms 推理约束内评估更高分辨率或多尺度方案。
3. 训练仅更新瓶颈与解码器，计算成本较低且具有较好的稳定性，但固定主干无法针对特定工业纹理进行适配。可在不破坏离线和复现要求的前提下探索参数高效微调或更合适的层融合策略。
4. 图像级分数使用训练正常样本的最小值和最大值确定中心与尺度，再通过 $\arctan$ 保序映射到 $(0,1)$ 。若训练与评测数据分布差异较大，校准范围仍可能影响分数尺度，可进一步比较鲁棒分位数校准。

8. 结论

本文给出了一个基于冻结 DINOv2 特征重建的工业异常检测方案。方案利用正常样本训练轻量瓶颈与解码器，通过多层编码—解码特征的余弦距离同时完成像素级定位和图像级判别。项目以 manifest 驱动数据访问，通过本地权重和模型文件支持离线加载，并按照 `category` 与 `image_name` 输出 `pred.json` 及二维 `float32` 像素异常图。

实验部分保留了历史最佳基准并补充了后续三次记录，且已统一为同时包含 Pixel F1、Pixel AP、Image F1、Image AP 与 Pixel AUROC 的 $[0,1]$ 加权平均口径。当前版本的加权平均分为 0.6724 (67.2%)。后续可继续补充失败案例、运行资源记录和盲测反馈，以验证公开开发集上的趋势能否保持。